

2026학년도 NEIT-AX 하계 연구소 인턴십 결과보고서

○ 연구주제	LLM RAG기반 거짓 주장 탐지 연구		
○ 성명	오정민	○ 학번	20223085
○ 연구소	AI컴퓨팅연구소		

1. 연구목표

- Open Domain Question Answering (ODQA) 은 문서 코퍼스에서 질문에 대한 답을 찾아내는 과업으로 Retriever가 질문과 관련된 문서를 검색하고 Reader가 답변한다, 이를 배경으로 Retriever-Reader 파이프라인을 구성한다.
- Leveraging Passage Retrieval with Generative Models for Open Domain Question Answering에서 제안된 Fusion-in-Decoder(FiD) 구조를 재현하여 질의응답 과업에서 다중 문서 처리 방법과 비교한 성능을 확인한다.
- 재현한 구조를 기반으로 과학 주장 팩트체크 과업으로 확장하고, Retriever와 Reader를 교체하며, 과업 변화에 따른 구조의 적용 가능성과 구성요소가 최종 평결 예측 성능에 미치는 영향을 분석한다.

2. 연구내용

2.1 Retriever-Reader 구조 기반 FiD 재현

ODQA에서는 질문에 필요한 근거가 여러 검색 문서에 분산되어 존재할 수 있으므로, 검색된 다중 문서의 정보를 효과적으로 통합하여 답변에 활용하는 능력이 중요하다. 이에 본 연구에서는 주어진 질문과 관련된 문서를 검색하고, 검색된 각 문단을 질문과 함께 독립적으로 인코딩한 뒤 디코더에서 통합하여 답변을 생성하는 FiD 구조를 재현하여 다중 근거 문서 통합이 답변 성능에 미치는 영향을 확인해 보고자 한다. 재현 실험은 대표적인 질의응답 데이터셋 Natural Questions을 대상으로 하며, 기존에 존재하는 Retriever-Reader 기반 구조인 DPR과 RAG를 베이스라인 파이프라인으로 설정하였다. DPR은 밀집 검색기로 관련 문단을 찾고 별도의 추출형 Reader가 답을 예측하며, RAG는 검색과 생성기를 결합해 검색 문서에 조건부로 답변을 생성한다.

2.2 검색 성능 재현 결과

Wikipedia 코퍼스에서 검색을 통해 근거 문서가 상위 k개의 검색 결과에 포함되는지를 Recall@k로 평가하였다.

Retriever	Recall@20	Recall@100
DPR (논문)	78.4	85.4
DPR (재현 결과)	80.0	85.9

검색 결과, 재현 실험에 사용한 모델 checkpoint의 차이로 성능이 소폭 상승 하였다.

2.3 답변 성능 재현 결과

구조	원 논문 보고값	재현 결과
DPR	41.50	39.75
RAG	44.50	41.11
FiD	51.40	49.67

최종 답변은 Exact Match로 평가하였으며, 재현 실험에 사용한 모델 checkpoint의 차이로 결과의 절대값은 원 논문 보고값보다 낮았지만, 각 파이프라인의 상대적 순위 (DPR < RAG < FiD)는 동일하게 유지되었다. 따라서 동일한 평가 조건에서 FiD의 다중 문서 통합 방식이 가장 높은 질의응답 성능을 보였음을 확인하였다.

2.4 과학 주장 팩트체크 과업 적용 및 Retriever-Reader 조합 비교

과학 주장 팩트체크는 주어진 주장과 관련된 근거 문서를 검색한 후, 검색된 근거를 Reader에 입력하여 주장에 대한 최종 평결을 예측하는 과업으로 질의응답 과업에 사용한 Retriever-Reader 파이프라인을 적용할 수 있다. 특히 과학 주장 팩트체크는 주장에 대한 근거가 문서의 여러 위치에 분산되어 존재하는 경우가 많아, 다중 근거 문서를 통합하는 FiD가 효과적으로 활용 될 수있다. 실험을 위해 Sparse Retriever (TF-IDF, BM25)와 Dense Retriever (DPR, Contriever)를 검색 모델로, Reader는 FiD 기반 Seq2Seq (BART, T5)와 대규모 언어 모델인 Qwen2.5-7B를 사용하였

다.

2.5 검색 성능 결과

SciFact 코퍼스에서 검색을 통해 정답 근거 문서가 상위 k개의 검색 결과에 포함되는지를 Recall@k로 평가하였다.

Retriever	Recall@1	Recall@3	Recall@5
TF-IDF	59.6	75.5	82.5
BM25	72.3	87.2	89.4
DPR	64.4	77.7	81.4
Contriever	64.4	81.9	86.7



검색 결과, Sparse Retriever인 BM25가 가장 높은 검색 성능을 보였다. Dense Retriever 중에서는 Contriever가 k=3과 k=5에서 DPR보다 높은 성능을 보였다.

2.6 평결 예측 성능 결과

각 Sparse, Dense Retriever에서 성능이 가장 높은 BM25와 Contriever를 대상으로, 검색된 상위 3개의 근거 문서를 활용하여 Reader별 Accuracy와 Macro-F1을 비교하였다. Qwen2.5-7B는 주장과 검색된 근거 문서를 사용하여 예측한 평결 레이블을 반환하도록 입력 프롬프트를 구성하였다.

Reader	BM25		Contriever	
	Accuracy	Macro-F1	Accuracy	Macro-F1
FiD-BART	59.1	53.9	58.0	52.3
FiD-T5	72.3	69.2	70.2	67.1
Qwen2.5-7B	80.9	80.3	73.4	74.4

실험 결과, Qwen2.5-7B를 Reader로 사용한 모든 조합에서 가장 높은 성능을 보였다. 이는 방대한 웹 문서를 기반으로 학습된 대규모 언어 모델의 특성을 고려했을 때, 여러 근거 문서의 정보를 종합하고 최종 평결을 예측하는 데 모델의 규모와 추론 능력이 성능에 더 큰 영향을 미치는 것으로 해석할 수 있다. FiD 계열 내에서도 모델의 파라미터 수가 더 큰 T5 기반 FiD-T5에서 일관되게 높은 성능을 보이며, FiD의 다중 문서 통합 구조가 팩트체크 과업에도 적용될 수 있음을 확인하였다. 또한, 동일한 Reader를 기준으로 비교했을 때, Sparse Retriever인 BM25를 검색 모델로 사용한 조합이 Contriever 조합보다 전반적으로 높은 성능을 보였다. 이를 통해, 근거 문서 검색 성능이 최종 평결 예측 성능으로 이어질 수 있음을 보여주며, 팩트체크 과업에서는 Reader의 성능뿐 아니라 적절한 검색 모델을 선택하는 것도 중요함을 시사한다.



추가적으로 검색 문서의 수에 따른 평결 예측 성능을 확인하기 위해, 각 검색기가 반환하는 상위 문서 수 k를 1, 3, 5로 변경하며 Reader별 Accuracy를 비교하였다. 전반적으로 Qwen2.5-7B가 FiD 계열 Reader보다 높은 성능을 보였다. Qwen2.5-7B와 Contriever 조합에서는 k가 증가할수록 성능이 향상되었지만, 다른 Retriever-Reader 조합에서는 일관된 성능 향상 경향을 보이지 않았다. 특히 FiD-T5는 k가 증가할수록 성능이 감소했으며, Qwen2.5-7B와 BM25의 조합에서는 k=3에서 가장 높은 성능을 기록한 뒤 k=5에서 감소하였다. 이는 검색 문서 수의 증가가 항상 평결 예측 성능 향상으로 이어지는 것은 아니며, 그 효과가 검색된 문서의 관련성과 Reader의 다중 문서 처리 능력에 따라 달라질 수 있음을 시사한다. 현재 실험에서는 초록 전체를 하나의 검색 단위로 사용하였는데, k가 증가하면 주장과 직접 관련되지 않은 문장도 Reader에 함께 입력될 수 있다. 따라서 후속 연구에서는 검색 단위를 문장 또는 passage 수준으로 세분화하고 재순위화를 적용하여 관련성이 높은 근거만 선별했을 때의 성능 변화를 비교할 필요가 있다.

3. 후속 연구 계획

- 검색 단위를 문서에서 문장 또는 passage 수준으로 세분화하고, 검색 결과의 재순위화를 통해 관련성이 높은 근거를 선별한 뒤 평결 예측 성능의 변화를 분석한다.
- FiD 구조를 한국어 질의응답 및 팩트체크 데이터셋에 적용하여 언어 변화에 따른 평결 예측 성능을 분석한다.